

Klasifikasi Kualitas Susu Sapi Menggunakan Algoritme *Support Vector Machine (SVM)* (Studi Kasus: Perbandingan Fungsi Kernel Linier dan *RBF Gaussian*)

Arif Indra Kurnia¹, Muhammad Tanzil Furqon², Bayu Rahayudi³

Program Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya

Email: ¹arifindrakurnia@gmail.com, ²m.tanzil.furqon@ub.ac.id, ³ubay1@ub.ac.id

Abstrak

Susu sapi mengandung protein hewani yang sangat besar manfaatnya bagi bayi maupun mereka yang sedang dalam proses pertumbuhan, karena susu sapi mengandung asam amino esensial dalam jumlah yang cukup. UTP Laboratorium Kesehatan Hewan Malang sebagai unit pelaksana teknis di bawah Dinas Peternakan Jawa Timur bertugas melakukan pengujian di bidang kesmavet untuk upaya pengamanan susu sebagai produk peternakan dengan pengujian yang tepat sesuai dengan Standar Nasional Indonesia (SNI). Pengklasifikasian kualitas susu sapi di UPT tersebut masih dilakukan secara *organoleptic* (bau, rasa, dan warna) yang bersifat linguistik sehingga variabel dan penentuan parameter bersifat tidak pasti dan menjadi kendala utama pakar dalam menentukan kualitas susu yang baik. Untuk mengatasi permasalahan tersebut dibutuhkan suatu sistem klasifikasi yang mampu mengklasifikasikan kualitas susu sapi yang baik menggunakan metode *support vector machine* yang mana kinerja SVM lebih cocok dibandingkan dengan metode klasifikasi lainnya. Data yang digunakan dalam penelitian ini yaitu 269 yang dibagi menjadi data latih dan data uji dengan tiga hasil kualitas susu yaitu rendah, standar, dan tinggi. Hasil akurasi penelitian ini mendapatkan akurasi terbaik berdasarkan percobaan *K-Fold Cross Validation* sebanyak 10 *Fold*, dengan menggunakan *kernel* RBF dan *kernel* Linier dengan nilai parameter λ (*lambda*) = 0,0001, *C* (*complexity*) = 1, γ (*gamma*) = 0,0001, *itermax* = 30 dan untuk nilai σ *kernel* RBF = 10. Hasil akurasi tertinggi menggunakan metode SVM pada klasifikasi kualitas susu sapi menggunakan *kernel* RBF sebesar 96% dan hasil akurasi tertinggi menggunakan *kernel* Linier sebesar 62%.

Kata Kunci: Susu sapi, Klasifikasi, *Support Vector Machine (SVM)*, *Kernel RBF*, *Kernel Linier*.

Abstract

Cow milk has a lot of animal protein and have benefit for children and whoever in process for grow up. Cow milk contains good essential amino acids. Malang Animal Health Laboratory as the unit executor in east java Animal Husbandry Department do a test in kesmavet for efforts to secure milk as a farm product with appropriate testing in suitable with the Indonesian National Standard (SNI). The classification of cow milk quality is still using *organoleptic* (smell, taste, color) that are linguistic, so that variable and parameter are uncertain and become the main obstacle of expert in determining good milk quality. To resolve this issue, this can be done with schizophrenia classification using support vector machine (SVM) algorithm, which SVM performance is more suitable than other classification methods. In this study there are 269 data that is divided into two data that is data training and data testing with three classification result, that is low, medium, and high. The result in this paper get the best accuracy based *K-Fold Cross Validation* as much 10 fold, with *Kernel RBF* and *Kernel Linear* with value λ (*lambda*) = 0,0001, *C* (*complexity*) = 1, γ (*gamma*) = 0,0001, maximum iteration = 30 and σ *kernel* RBF = 10. The highest accuracy using SVM method in cow milk quality classification use *Kernel RBF* was 96% and the highest accuracy use *Kernel Linear* was 62%.

Keywords: Cow Milk, Classification, *Support Vector Machine (SVM)*, *Kernel RBF*, *Kernel Linear*.

1. PENDAHULUAN

Susu sapi merupakan bahan pokok pangan yang bergizi tinggi karena mengandung

komponen zat makanan yang lengkap dan seimbang seperti protein, lemak, karbohidrat, mineral, kalsium, asam amino esensial maupun non-esensial dan vitamin yang sangat dibutuhkan oleh manusia. Maka dari itu mengkonsumsi susu sapi sangatlah dianjurkan untuk orang dewasa maupun anak-anak sebagai penyempurna dari makanan pokok seperti nasi, lauk pauk, sayur dan buah-buahan. Selain untuk memenuhi kebutuhan gizi manusia banyak produk dapat dibuat dari susu sapi seperti makanan, minuman, keju, mentega, yogurt, dll.

Nilai gizi yang tinggi juga menyebabkan susu merupakan medium yang sangat disukai oleh mikroorganisme untuk pertumbuhan dan perkembangannya sehingga dalam waktu yang sangat singkat susu menjadi tidak layak di konsumsi bila tidak ditangani secara benar. Mikroorganisme yang berkembang di dalam susu selain menyebabkan susu menjadi rusak juga membahayakan kesehatan masyarakat sebagai konsumen akhir. Disamping itu penanganan susu yang benar juga dapat menyebabkan daya simpan susu menjadi singkat yang pada akhirnya juga akan berpengaruh terhadap kualitas dari susu sapi. Jika kualitas dan kandungan gizi dari susu sapi kurang dari standar maka sudah tidak layak untuk dikonsumsi oleh konsumen.

Faktor kualitas susu sangat berpengaruh terhadap baik maupun buruknya dalam jumlah gizi di dalamnya. Saat masih dalam kelenjar susu, susu dinyatakan steril. Namun apabila sudah terkena udara, susu sudah tidak bisa dijamin kesterilannya. Oleh karena itu perlu dilakukan pengujian dalam menentukan kualitas susu agar dapat dinyatakan sebagai susu berkualitas baik. Berdasarkan Standar Nasional Indonesia (SNI) 3141.2011 syarat mutu susu segar adalah berat jenis (pada suhu 27,5°C) minimal 1.0270, kadar lemak maksimal 3%, kadar bahan kering tanpa lemak 7,8%, kadar protein minimal 2,8%, warna, bau dan rasa tidak ada perubahan. Deraat asam 6 – 7°SH. Uji alkohol (70%) negatif, uji katalase maksimal 3cc. Angka refraksi 36 – 36, angka reduktase 2 – 5 jam (Ace et al., 2010).

Metode yang diterapkan dalam pengklasifikasian sangat penting dalam menentukan kualitas susu sapi. Metode yang digunakan juga dapat banyak membantu peran seseorang pakar dalam menentukan kualitas susu yang dihasilkan berdasarkan faktor-faktor yang mempengaruhinya. Sehingga dibutuhkan

penentuan metode yang tepat untuk bisa mendapatkan hasil yang maksimal dan juga akurat dalam pengklasifikasian kualitas susu sapi. Dengan semakin berkembangnya kemajuan teknologi komputer juga metode-metode klasifikasi didalamnya, maka diperlukan suatu sistem perangkat lunak bantu yang akan dikembangkan dalam skripsi ini.

Metode yang digunakan dalam penelitian ini yaitu algoritme *Support Vector Machine*. algoritme *Support Vector Machine* adalah metode pembelajaran mesin yang bekerja atas prinsip *Structural Risk Minimization* (SRM) dengan tujuan menemukan hyperplane terbaik yang memisahkan dua buah class pada input space. *Support Vector Machine* (SVM) dikenal sebagai teknik pembelajaran mesin paling mutakhir setelah pembelajaran mesin sebelumnya.

Pada penelitian sebelumnya membahas parameter-parameter apa saja yang digunakan untuk menentukan kualitas susu sapi sehingga menghasilkan kualitas yang terbaik. Dari penelitian tersebut dapat disimpulkan bahwa kualitas susu yang diuji meliputi berat jenis, kandungan lemak dan kualitas susu. Semakin banyak jumlah konsentrat yang diberikan akan meningkatkan berat jenis susu dan menurunkan lemak susu. Semakin tinggi tingkat mastitis subklinis akan meningkatkan lemak susu.

Berdasarkan latar belakang yang telah diuraikan dan penjelasan dari penelitian sebelumnya, maka pada skripsi ini akan dibuat dengan judul “Klasifikasi Kualitas Susu Sapi Menggunakan Algoritme *Support Vector Machine* (Studi Kasus: Perbandingan Fungsi Kernel *Linier* Dan *RBF Gaussian*)”. Data yang digunakan dalam pengklasifikasian kualitas susu sapi berupa tujuh parameter yaitu *FAT*, *SNF*, *Density*, *Protein*, *Lactosa*, Kadar Air dan *Temperature*.

2. DASAR TEORI

2.1 Susu Sapi

Menurut Badan Penelitian dan Pengembangan Teknologi Pertanian, susu adalah hasil pemerahan dari ternak sapi perah atau dari ternak menyusui lainnya yang pemerahannya dilakukan secara kontinyu bahkan kandungan-kandungan yang terkandung didalamnya tidak dikurangi dan tidak ditambahkan bahan-bahan lain karena lebih memiliki nilai gizi cukup banyak dan dapat digunakan untuk segala usia. Susu yang diperah

dari seekor sapi mengandung $\pm 8.25\%$ padatan bukan lemak (SNF) serta $\pm 3.25\%$ lemak susu (FAT).

Nutrisi yang terkandung dalam susu misalnya saja protein, lemak dan laktosa memiliki peran penting bagi tubuh manusia. Selain itu susu juga mengandung hidrat arang, vitamin A, mineral, asam amino esensial dan non-esensial (Suparlan, 2007). Dengan adanya hal tersebut tentunya susu berperan penting sebagai asupan untuk kesehatan, kecerdasan dan pertumbuhan, khususnya anak-anak. Dengan manfaat susu yang begitu menguntungkan sehingga banyak dikonsumsi masyarakat, menjadikan susu sebagai salah satu komoditas ekonomi yang mempunyai nilai strategis.

2.2 Faktor yang Berpengaruh Terhadap Kualitas Susu Sapi

Kualitas susu ditentukan oleh dua macam syarat yaitu sifat-sifat fisika dan kimia serta mikrobiologi yang terkandung di dalam susu. Syarat-syarat ini berhubungan erat dengan rasa dan bau. Susu terasa sedikit manis yang disebabkan oleh laktosa. Rasa asin pada susu berasal dari klorida, sitrat dan garam-garam mineral lainnya (Saleh, 2004). Dalam penelitian ini mengacu dari beberapa aktor yang mempengaruhi kualitas susu yaitu FAT, SN, Density, Protein, Laktosa, kadar air dan temperatur. Dari karakteristik tersebut harus mengikuti syarat yang telah ditentukan oleh Badan Standar Nasional Indonesia seperti digambarkan pada Tabel 1:

Tabel 1 Standar Mutu Susu Segar

No	Jenis Uji	Satuan	Persyaratan
1	Berat jenis (27,5°C)	g/cm ³	min 1,0280
2	Kadar Lemak	%	min 3,0
3	SNF	%	min 8,0
4	Kadar protein	%	min 2,7
5	Cemaran logam:		
	Timbal (Pb)		maks 0,3
	Seng (Zn)	ppm	maks 0,5
	Merkuri (Hg)		maks 0,5
	Arsen (As)		maks 0,5
6	Organoleptik: warna, aroma, rasa, kekentalan	-	tidak ada perubahan
7	Kotoran dan benda asing	-	Negatif
8	Cemaran mikroba:		1.10 ⁶
	Total kuman		
	<i>Salmonella</i>		Negatif
	<i>Eschericia coli</i>	cfu/m	Negatif

(patogen)	1	
Coliform		20
<i>Streptococcus</i> group B		Negatif
<i>Staphylococcus aureus</i>		100
9	Jumlah sel radang	/ml maks 4.10 ⁴
10	Uji Katalase	cc maks 3
11	Uji Reduktase	jam 2-5
12	Residu antibiotika, pestisida, Insektisida	- Negatif
13	Uji alkohol (70%)	- Negatif
14	pH	- 6-7
15	Uji pemalsuan	- Negatif
16	Titik beku	°C -0,520 s/d -0,560
17	Uji Peroksidase	- Positif

2.3 Klasifikasi

Klasifikasi merupakan suatu proses untuk menemukan sekumpulan model maupun fungsi yang menjelaskan dan membedakan data kedalam kelas-kelas tertentu, dengan tujuan menggunakan model tersebut dalam menentukan kelas dari suatu objek yang belum diketahui kelasnya.

Ada dua proses dalam klasifikasi, yaitu:

1. Proses *learning/training*: melakukan pembangunan model menggunakan data training.
2. Proses *testing*: melakukan tes terhadap data testing menggunakan model yang telah diperoleh dari proses training.

2.4 Support Vector Machine (SVM)

Support Vector Machine (SVM) dikembangkan pertama kali oleh Boser, Guyon, dan Vapnik. SVM untuk pertama kali dipresentasikan pada sebuah Workshop on Computation Learning Theory. *Support Vector Machine* (SVM) memiliki prinsip dasar yaitu *linear classifier*, dan selanjutnya dikembangkan agar dapat bekerja pada masalah seperti non-linear dengan memasukkan konsep kernel trik pada ruang kerja berdimensi tinggi. SVM sendiri merupakan usaha untuk mencari *hyperplane* terbaik yang berfungsi sebagai pemisah dua buah *class* pada *input space* dengan cara menghitung nilai margin yang mana merupakan jarak antara *hyperplane* dengan pola terdekat dari setiap kelas, yang mana pola yang itu disebut sebagai *support vector*. Margin dapat

dihitung dengan rumus $1/\|w\|$.

2.5 Support Vector Machine Linier

SVM linier dibagi menjadi dua, yaitu *separable* dan *non-separable*. SVM melakukan klasifikasi himpunan data *training* berpasangan dari dua kelas. Klasifikasi linier adalah klasifikasi data yang memisahkan data secara linier. Misal diketahui $x_i = \{x_1, \dots, x_n\}$ adalah titik pada dataset, dan $y_i = y \in \{+1, -1\}$ adalah *class* pada data x_i . Bidang pemisah terbaik adalah yang dapat memisahkan semua data set yang sesuai dengan *class* dan memiliki margin paling besar. Bidang pemisah pertama membatasi *class* pertama, sedangkan bidang pemisah kedua membatasi *class* kedua, sehingga diperoleh Persamaan 1 dan Persamaan 2.

$$(w \cdot x_i + b) \geq +1 \text{ untuk } y_i = +1 \quad (1)$$

$$(w \cdot x_i + b) \geq -1 \text{ untuk } y_i = -1 \quad (2)$$

Variabel w merupakan bidang normal antara bidang pemisah terhadap pusat koordinat, dan variabel b adalah posisi bidang relatif terhadap pusat koordinat. Jarak antara *hyperplane* dan titik terdekat untuk menemukan margin terbesar adalah dengan memaksimalkan fungsi $\frac{1}{\|w\|}$ atau dengan meminimalkan $\|w\|^2$. Untuk bidang pemisah atau *hyperplane* kedua *class* dijelaskan pada Persamaan 3.

$$y_i(w \cdot x_i + b) \geq 1, i = 1, 2, \dots, n \quad (3)$$

Persamaan 3 dapat dirumuskan sebagai *Quadratic Programming* dengan mencari titik minimal. *Hyperplane* terbaik dengan margin terbesar dapat dirumuskan menjadi masalah optimasi *constraint* pada Persamaan 4.

$$\text{Min} = \frac{1}{2} \|w\|^2 \quad (4)$$

Dimana syarat $y_i(w \cdot x_i + b) \geq 1$. Persamaan 2.4 digunakan untuk menyelesaikan permasalahan optimasi yang dapat diselesaikan dengan menggunakan fungsi *Lagrange*. Fungsi *Lagrange* yang digunakan adalah *Lagrange multiplier* dijelaskan pada Persamaan 5.

$$\text{Min } L(w, b, a) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i [y_i(w \cdot x_i + b) - 1] \quad (5)$$

Dimana α_i merupakan nilai bobot dari setiap titik data. Notasi ini bernilai nol atau positif ($\alpha_i \geq 0$), dengan meminimalkan nilai L terhadap w dan b , maka untuk menghitung w dan b dapat menggunakan Persamaan 6.

$$w = \sum_{i=1}^n \alpha_i y_i x_i$$

dan

$$b = -\frac{1}{2}(w \cdot x^+ + w \cdot x^-) \quad (6)$$

Dimana x^+ merupakan nilai dari salah satu *support vector* dari *class positive* dan x^- merupakan nilai dari salah satu *support vector* dari *class negative*. Persamaan 6 dapat dimodifikasi menjadi fungsi maksimal untuk mencari *hyperplane* terbaik. Dapat dilihat pada Persamaan 7.

$$\max \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i x_j \quad (7)$$

$$\alpha_i \geq 0 (i = 1, 2, \dots, n) \text{ dan } \sum_{i,j=1}^n \alpha_i y_i = 0$$

Hasil dari perhitungan pada Persamaan 7 dapat diperoleh nilai α_i bernilai positif, dan selanjutnya akan digunakan untuk menemukan w . Pada setiap data *training*, terdapat nilai α_i . *Support vector* adalah data *training* yang mempunyai nilai $\alpha_i > 0$, sedangkan sisanya memiliki nilai $\alpha_i = 0$. Jadi, fungsi keputusan yang dihasilkan hanya dipengaruhi oleh *support vector*. Untuk mendapatkan klasifikasi yang optimal data *testing* x dapat digunakan Persamaan 8. Hasil klasifikasi dapat dilihat pada Persamaan 9.

$$f(x) = \sum_{i=1}^m \alpha_i y_i x_i \cdot x + b \quad (8)$$

$$f(x) = (w \cdot x + b) \quad (9)$$

Fungsi Klasifikasi = $\text{sign}(f(x))$

Keterangan variabel m adalah jumlah *support vector* atau titik data yang memiliki $\alpha_i > 0$, dan notasi x merupakan data yang akan diklasifikasikan.

2.6 Support Vector Machine (SVM) RBF

Permasalahan *non-linier* dapat diselesaikan dengan mentransformasikan ke dalam permasalahan linier dengan menggunakan dimensi yang tinggi. Fungsi *kernel* dapat didefinisikan menjadi *input kernel trick*. *Kernel trick* adalah bagian dari pembelajaran dalam metode SVM untuk mengetahui fungsi *kernel* tanpa harus mengetahui wujud dari fungsi *non-linier*. Untuk menghitung *kernel trick* ditunjukkan pada Persamaan 10.

$$K(x_i, x_j) = \Phi(x_i) \cdot \Phi(x_j) \quad (10)$$

Notasi x_i, x_j dengan *dot product* dapat diganti dengan simbol K . Model *quadratic problem* dapat digunakan untuk mendapatkan *hyperplane* yang optimal dengan menggunakan

persamaan klasifikasi data *non-linier*. Dapat ditunjukkan pada Persamaan 11.

$$\min \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \cdot y_i \cdot K(x_i, x_j) \quad (11)$$

Dengan batasan berikut

$$\sum_{i=0}^n \alpha_i y_i = 0, 0 \leq \alpha_i \leq C, \text{ dan } i = 1, 2, \dots, n$$

Nilai $K(x, y)$ merupakan fungsi *kernel* yang menunjukkan pemetaan *non-linier* pada *feature space*. Pada Persamaan 12 merupakan fungsi keputusan klasifikasi optimal.

$$f(x) = \sum_{i=1}^m \alpha_i \cdot y_i \cdot K(x_i, x_j) + b \quad (12)$$

Berikut adalah beberapa fungsi *kernel*:

- Fungsi *Linier* ditunjukkan pada Persamaan 13.

$$K(x, y) = x \cdot y \quad (13)$$

- Fungsi *Polynomial* ditunjukkan pada Persamaan 14.

$$K(x, y) = (x \cdot y)^d \quad (14)$$

- Fungsi *Gaussian RBF* ditunjukkan pada Persamaan 15.

$$K(x, y) = \exp\left(-\frac{\|x-y\|^2}{2\sigma^2}\right) \quad (15)$$

- Fungsi *Sigmoid* didefinisikan pada Persamaan 16.


$$K(x, y) = \tanh(\sigma(x, y) + C) \quad (16)$$

Kernel linier adalah *kernel* yang digunakan ketika data yang diklasifikasikan dipisahkan oleh sebuah garis atau *hyperline*. Sedangkan *kernel non-linier* adalah *kernel* yang digunakan ketika data yang diklasifikasikan dipisahkan dengan garis lengkung atau sebuah bidang pada ruang yang berdimensi tinggi.

3. PENGUJIAN DAN ANALISIS

3.1 Analisis Pengujian *K-fold Cross Validation*

Pada pengujian skenario *k-fold cross validation*, *dataset* yang digunakan sebanyak 269 data yang terdiri dari tiga kelas. Data tersebut akan dibagi sebanyak 10 *fold* dengan sembilan *fold* diantaranya berisi 27 *dataset* dan satu *fold* berisi 26 *dataset* secara acak yang kesemuanya mewakili setiap kelasnya.



Gambar 1. Hasil Pengujian *K-fold Cross Validation*

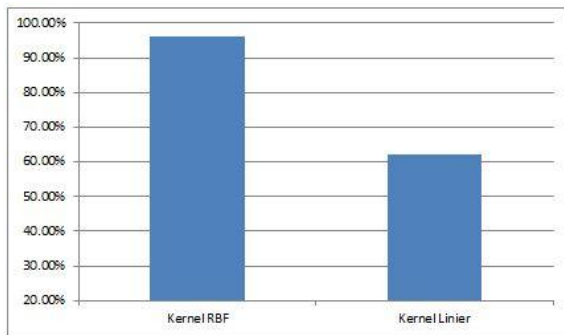
Pengujian ini menggunakan *kernel RBF* dan *kernel Linier* dengan nilai parameter *sequential training SVM* yang digunakan dalam pengujian ini yaitu λ (*lambda*) = 0,0001, γ (*gamma*) = 0,0001, *itermax* = 30, *C* (*Complexity*) = 1, dan untuk nilai σ *Kernel RBF* = 10. Hasil pengujian perbandingan rasio data dilihat pada Gambar 1.

Analisis dilakukan pada pengujian skenario *k-fold cross validation* yaitu tingkat akurasi terhadap perbandingan *fold* data yang memiliki rata-rata akurasi paling baik. Dari total 269 *dataset* yang digunakan akan dibagi sebanyak 10 *fold* dengan 9 *fold* diantaranya berisi 27 *dataset* dan 1 *fold* berisi 26 *dataset* yang kesemuanya mewakili setiap kelasnya (kelas rendah, sedang dan tinggi). Hal ini menunjukkan bahwa pada *fold 7* nilai-nilai atribut datanya sangat mewakili tiap-tiap kelasnya sehingga sangat akurat dijadikan data latih. Data ini merupakan sebaran data latih dan data uji terbaik dalam pengujian ini, walaupun pengambilan data kedalam setiap *fold* secara acak.

3.2 Pengujian Jenis *Kernel*

Nilai parameter *sequential training SVM* yang digunakan dalam pengujian ini yaitu *parameter sequential training* λ (*lambda*) = 0,0001, γ (*gamma*) = 0,0001, *itermax* = 30, *C* (*Complexity*) = 1, dan untuk nilai σ *Kernel RBF* = 10. Data yang digunakan dalam pengujian ini yaitu dengan *k-fold cross validation* dan *fold 7* sebagai data latihnya. Hasil pengujian terhadap *Kernel SVM* dapat dilihat pada Gambar 2.


Analisis pengujian yang dilakukan pada jenis *kernel* yaitu tingkat akurasi terhadap pengaruh jenis *kernel*. Pada Gambar 2. Hal ini menunjukkan jika *kernel RBF* lebih cocok digunakan pada penelitian ini dibandingkan dengan *kernel linier*.

Gambar 2. Hasil Pengujian *Kernel*


3.3 Pengujian Parameter λ (*Lambda*)

Nilai λ (*lambda*) yang digunakan yaitu 0,0001, 0,001, 0,01, 0,1, 1, 1,5, 2,5, 5, 8 dan 10. Nilai parameter *sequential training SVM* yang digunakan dalam pengujian ini γ (*gamma*) = 0,00001, *itermax* = 10, *C* (*Complexity*) = 1, dan untuk nilai σ *Kernel RBF* = 0.1. Data yang digunakan dalam pengujian ini yaitu dengan *k-fold cross validation* dan fold 1 sebagai data latihnya. Hasil pengujian λ (*lambda*) dilihat pada Gambar 3.

Hasil analisis yang dilakukan pada pengujian nilai λ (*lambda*) yaitu tingkat akurasi terhadap pengaruh dari nilai λ (*lambda*). Pada skenario pengujian ini menunjukkan nilai akurasi yang paling baik ditunjukkan pada nilai λ (*lambda*) = 0,0001, 0,001, 0,01, 0,1, 1 dan 1,5 pada kernel RBF dengan rata-rata akurasi sebesar 92% dan nilai λ (*lambda*) = 0,0001, 0,001, 0,01 dan 0,1 pada kernel Linier dengan rata-rata sebesar 62%. Hal ini menunjukkan bahwa semakin besarnya nilai dari λ (*lambda*) tidak menentukan akurasi semakin baik karena setelah nilai *lambda* melebihi 5 akurasinya semakin turun. Jika nilai *lambda* terlalu besar dapat mengakibatkan waktu komputasi pada perhitungan matriks *Hessian* lebih lama, dikarenakan *augmented factor* (*lambda*) dapat berdampak sistem lambat mencapai konvergensi dan tidak stabilnya proses pembelajaran.

Gambar 3. Hasil Pengujian *Lambda*


3.4 Pengujian Parameter γ (*Gamma*)

Gambar 4. Hasil Pengujian Nilai *Gamma*

Analisis dilakukan pada pengujian nilai konstanta *gamma* yaitu tingkat akurasi terhadap pengaruh nilai konstanta *gamma*. Pada pengujian konstanta *gamma* nilai yang paling optimal ditunjukkan pada nilai 0,0001 yang nilai rata-rata akurasinya sebesar 92% untuk kernel RBF dan nilai 0,0001 yang nilai rata-rata akurasinya sebesar 62% untuk kernel Linier. Nilai *gamma* berpengaruh terhadap hasil akurasi hal ini ditunjukkan pada grafik diatas pada kernel RBF saat nilai konstanta *gamma* 0,1 maka hasil akurasinya akan semakin menurun, begitu juga dengan kernel Linier pada saat nilai konstanta *gamma* 0,001 semakin menurun. Semakin besar nilai konstanta *gamma* maka akan semakin besar nilai *learning rate* dan akurasi cenderung tidak stabil, *Learning rate* merupakan nilai pembelajaran, apabila nilai dari *learning rate* semakin besar maka proses pembelajaran akan semakin cepat. Namun apabila nilai dari *learning rate* terlalu besar, pada umumnya proses latih dapat melampaui keadaan yang optimal, semakin besar *learning rate* akan menyebabkan berkurangnya ketelitian dari sistem begitu juga sebaliknya.

3.5 Pengujian Parameter *C* (*Complexity*)

Nilai *C* (*Complexity*) yang digunakan yaitu 0,000001, 0,00001, 0,0001, 0,001, 0,1, 1, 10, 50, 80, 100. Nilai parameter *sequential training SVM* yang digunakan dalam pengujian ini λ (*lambda*) = 0,0001 γ (*gamma*) = 0,00001, *itermax* = 10, dan untuk nilai σ *Kernel RBF* = 0.1. Data yang digunakan dalam pengujian ini yaitu dengan *k-fold cross validation* dan fold 1 sebagai data latihnya. Hasil pengujian *C* (*Complexity*) dilihat pada Gambar 5.




Gambar 5. Hasil Pengujian Parameter C

Analisis dilakukan pada pengujian nilai complexity yaitu tingkat akurasi terhadap pengaruh nilai complexity (C). Pada skenario ini menunjukkan nilai akurasi paling optimal ketika berada pada 0,001 hingga 100 untuk kernel RBF dan 0,1 sampai 100 untuk kernel Linier. Tujuan dari pengujian parameter ini yaitu meminimalkan nilai *error* dan memperkecil nilai *slack variable*, pada saat nilai *C* menjauhi nilai 0, maka margin pemisah (*hyperplane*) akan semakin lebar dan jika nilai *C* semakin besar maka akan memberikan penalti yang besar terhadap nilai *error* pada klasifikasi.

3.6 Pengujian Pengujian σ Kernel RBF


Nilai σ (Sigma kecil) yaitu 0,1, 1, 1.5, 2, 2.5, 3, 3.5, 5, 8, 10. Nilai parameter *sequential training SVM* yang digunakan dalam pengujian ini λ (*lambda*) = 0,0001 γ (*gamma*) = 0,0001, *C* (*complexity*) = 1, *itermax* = 10. Data yang digunakan dalam pengujian ini yaitu dengan *k-fold cross validation* dan fold 1 sebagai data latihnya. Hasil pengujian sigma dapat dilihat pada Gambar 6.

Analisis dilakukan pada pengujian sigma σ kecil *kernel RBF*, Pada skenario ini menunjukkan nilai akurasi paling besar yaitu pada saat nilai σ sigma berada pada angka 10 dengan nilai akurasi tertinggi sebesar 92%. Hal ini disebabkan karena nilai σ dari *kernel RBF* digunakan untuk menyatikan variasi atau ketidakpastian sekelompok data.



Gambar 6. Hasil Pengujian Parameter Sigma

3.7 Pengujian Pengujian *Itermax*

Gambar 7. Hasil Pengujian *Itermax*

Nilai *itermax* = 10, 20, 30, 40, 50, 60, 70, 80, 90 dan 100. Nilai parameter *sequential training SVM* yang digunakan dalam pengujian ini λ (*lambda*) = 0,0001 γ (*gamma*) = 0,0001, *C* (*complexity*) = 1, dan untuk nilai σ *Kernel RBF* = 10. Data yang digunakan dalam pengujian ini yaitu dengan *k-fold cross validation* dan fold 1 sebagai data latihnya. Hasil pengujian terhadap parameter *sequential training SVM* dapat dilihat pada Gambar 7.

Analisis dilakukan pada pengujian jumlah iterasi yaitu tingkat akurasi terhadap pengaruh jumlah iterasi. Pada skenario ini menunjukkan nilai akurasi paling besar yaitu pada saat iterasi ke 10 sampai dengan 100 dengan nilai akurasi tertinggi yaitu 92% untuk kernel RBF dan nilai akurasi paling besar yaitu pada saat iterasi ke 10 dengan nilai akurasi 62% untuk kernel Linier. Pada iterasi 10 sampai dengan iterasi ke 100 pada kernel RBF dan iterasi ke 10 pada kernel Linier menunjukkan akurasi yang konvergen. Hal ini terjadi nilai α_i sudah mencapai nilai konvergen, yang mana dapat didefinisikan dari tingkat perubahan nilai α_i .

4. KESIMPULAN

Berdasarkan hasil penelitian, pengujian dan analisis dapat disimpulkan sebagai berikut:

1. Algoritme *Support Vector Machine* (SVM) pada *Kernel RBF* maupun *Kernel Linier* dapat diimplementasikan dengan baik, langkah pertama yaitu pengumpulan *dataset* susu sapi dengan tujuh atribut data yang meliputi *fat*, *SNF*, *density*, *protein*, *lactosa*, *air* dan *temperatur*. Kemudian dari data tersebut dilakukan pembagian data latih dan data uji menggunakan metode *K-Fold Cross Validation* sebanyak 10 *fold* yang dipilih secara acak namun setiap *fold*nya mewakili semua kelas data. Setelah melakukan pemilihan data latih dan data uji

menggunakan metode *K-Fold Cross Validation* dan mendapatkan data latih dan data uji yang terbaik kemudian dilakukan perhitungan matriks kernel RBF dan matriks kernel Linier dan dilanjutkan dengan proses perhitungan *sequential training*. Setelah diproses akan mendapatkan nilai a_i yang merupakan bobot data ke- i dan nilai b (bias) yang nantinya digunakan dalam proses *testing* dalam SVM. Hasil dari pengujian berupa hasil klasifikasi dari masing-masing kelas data uji. Hasil akhir berupa akurasi sistem yang didapat dari membandingkan kelas sebenarnya dengan kelas prediksi hasil dari pengujian baik menggunakan kernel RBF dan kernel Linier.

2. Hasil akurasi dari sistem klasifikasi kualitas susu sapi menggunakan metode Support Vector Machine (SVM) perbandingan ungu kernel Linier dan RBF Gaussian didapatkan akurasi terbaik pada kernel RBF dengan parameter λ ($lambda$) = 0,0001, C ($complexity$) = 1, γ ($gamma$) = 0,0001, $itermaks$ = 30 dan untuk nilai σ kernel RBF = 10 dan *fold* 7 sebagai data latih terbaik sebesar 96%, sedangkan akurasi terbaik pada kernel Linier dengan parameter λ ($lambda$) = 0,0001, C ($complexity$) = 1, γ ($gamma$) = 0,0001, $itermaks$ = 30 dan *fold* 7 sebagai data latih terbaik hanya sebesar 62%. Sehingga penerapan klasifikasi kualitas susu sapi menggunakan metode Support Vector Machine (SVM) didapatkan hasil yang lebih baik ketika menggunakan Kernel RBF Gaussian dari pada menggunakan Kernel Linier. Hal ini disebabkan karena adanya parameter σ ($sigma$) pada kernel RBF yang digunakan untuk menyatakan variasi atau ketidakpastian sekelompok data.

DAFTAR PUSTAKA

- Ace, I.S., Wahyuningsih. 2010. *Hubungan Variasi Pakan Terhadap Mutu Susu Segar di Desa Pasirbuncir Kecamatan Caringan Kabupaten Bogor*. Jurnal Penyuluhan Pertanian Vol.5 No.1
- Maimon, Oded dan Rokach, Lior. 2005. *Data Mining and Knowledge Discovery Handbook*. New York: Springer.
- Vercellis, C. 2009. *Business Intelligent: Data Mining and Optimization for Decision Making*. Southern Gate, Chichester, West Sussex: John Willey dan Sons, Ltd.
- Saleh, E. 2004. *Dasar Pengolahan Susu dan Hasil Ikutan Ternak*. S1. Universitas Sumatera Utara.
- Farid, M., Sukei, H. 2011. *Pengembangan Susu Segar Dalam Negeri Untuk Pemenuhan Kebutuhan Susu Nasional*. Buletin Ilmiah Litbang Perdagangan, Vol.5 No.2, Desember 2011.
- Suparlan, A., Nurhasanah, Budiharti, U. 2007. *Dukungan Teknologi Mekanisasi Pada Pengolahan Susu Untuk Skala Usaha Kecil Menengah*. Balai Besar Pengembangan Mekanisasi Pertanian, Serpong Jawa Barat.
- Revita, F. 2015. *Pengklasifikasian Mutu Susu Sapi Menggunakan Metode Learning Vector Quantization (LVQ) (Studi Kasus : UPT Laboratorium Kesehatan Hewan Malang)*. S1. Universitas Brawijaya.
- Kristiyanti, D.A. 2015. *Analisis Sentimen Review Produk Kosmetik Menggunakan Algoritme Support Vector Machine dan Particle Swarm Optimization Sebagai Seleksi Fitur*. Jurnal Seminar Inovasi dan Tren (SNIT) 2015.
- Nugroho, S., Witarto, B., Handoko. 2003. *Support Vector Machine – Teori dan Aplikasinya Dalam Bioinformatika*. Jurnal Kuliah Umum IlmuKomputer.Com.
- Kerami, D., Murfi, H. 2004. *Kajian Kemampuan Generalisasi Support Vector Machine Dalam Pengenalan Splice Site Pada Barisan DNA*. Makara, Sains, Vol. 8, No.3, Desember 2004 : 89-95.
- Utami, K.B., Radiati, L.E., Surjowardojo, P. 2015. *Kajian Kualitas Susu Sapi Perah PFH (studi kasus pada anggota Koperasi Agro Niaga Di Kecamatan Jabung Kabupaten Malang)*. Jurnal Ilmu-Ilmu Peternakan 24 (2) : 58-66. Fakultas Peternakan. Universitas Brawijaya.
- Supriyadi, E., Sensuse, D.I. 2015. *Optimasi Algoritme Support Vector Machine Dengan Particle Swarm Optimization Dalam Mendeteksi Ketepatan Waktu Kelulusan Mahasiswa : Studi Kasus Poltek LP3I Jakarta “Kampus Depok”*. Jurnal Seminar Nasional Inovasi dan Tren (SNIT) 2015.

Halim, F.,N. 2010. *Aplikasi Pengendalian Mutu Pada Pabrik Susu Sterilisasi Ultra High Temperature Plain Yang Berkapasitas 21.000 L/hari*. [Tabel] Tersedia di: <<http://repository.wima.ac.id/772/6/Lampiran.pdf>> [Diakses 6 Maret 2017]